

MÔ TẢ DATASET — KLTN EpiWeather v1

Sinh viên: Phạm Hữu Luân — MSSV 110122016 — DA22TTA **Đề tài:** Xây dựng hệ thống cảnh báo nguy cơ dịch bệnh theo mùa dựa trên dữ liệu y tế và thời tiết toàn cầu **Phiên bản:** v1 — 17/05/2026

1. Tổng quan các file dataset

File	Số dòng	Số cột	Dung lượng	Mục đích sử dụng
master_weekly_v1.csv	61113	27	20,9 MB	Dataset tích hợp gốc, dùng làm nguồn cho feature engineering và EDA
features_flu_v1.csv	51.208	21	14,8 MB	Bộ feature dùng để huấn luyện mô hình dự báo và phân loại cúm
features_dengue_v1.csv	996	20	1,6 MB	Bộ feature dùng để huấn luyện mô hình dự báo và phân loại sốt xuất huyết

Key chung của cả 3 file: `iso3` (mã quốc gia ISO Alpha-3) + `iso_year` (năm theo lịch ISO 8601) + `iso_week` (tuần ISO, từ 1 đến 52)

2. master_weekly_v1.csv — Dataset tích hợp

Mỗi dòng đại diện cho một bộ ba (quốc gia, năm ISO, tuần ISO). Dataset gộp ba nguồn dữ liệu: cúm (WHO FluNet), sốt xuất huyết (OpenDengue v1.3) và khí hậu (ERA5 ECMWF).

2.1. Cột định danh (3 cột)

Tên cột	Kiểu	Mô tả
iso3	string	Mã quốc gia chuẩn ISO Alpha-3 (ví dụ: VNM, USA, BRA)
iso_year	integer	Năm theo chuẩn ISO 8601 (2010-2019)
iso_week	integer	Số tuần ISO trong năm (1-52)

2.2. Cột dữ liệu cúm — nguồn WHO FluNet (4 cột)

Tên cột	Kiểu	Mô tả
INF_A	float	Số ca dương tính với virus cúm A trong tuần
INF_B	float	Số ca dương tính với virus cúm B trong tuần
influenza_total	float	Tổng số ca cúm = INF_A + INF_B (đã xử lý giá trị thiếu = 0). Đây là target gốc của bài toán dự báo cúm
HEMISPHERE	string	Bán cầu chứa quốc gia (NH = Bắc bán cầu, SH = Nam bán cầu). Quan trọng cho mùa cúm

2.3. Cột dữ liệu sốt xuất huyết — nguồn OpenDengue v1.3 (2 cột)

Tên cột	Kiểu	Mô tả
dengue_total	float	Số ca sốt xuất huyết được báo cáo trong tuần. NaN nếu quốc gia không báo cáo bệnh này
case_definition_standardized	string	Loại định nghĩa ca bệnh (Total, Suspected, Confirmed, ...). Đã chọn theo thứ tự ưu tiên Total > Suspected > Confirmed khi merge

2.4. Cột dữ liệu khí hậu — nguồn ERA5 ECMWF (18 cột)

Tất cả biến khí hậu được lấy trung bình theo tháng và broadcast xuống tuần. Đã ánh xạ từ lưới tọa độ $0,25^\circ \times 0,25^\circ$ sang mã quốc gia iso3 bằng KD-tree.

Nhiệt độ (5 cột):

Tên cột	Đơn vị	Mô tả
temp_c	°C	Nhiệt độ trung bình tại độ cao 2m
dewpoint_c	°C	Nhiệt độ điểm sương (dùng tính độ ẩm tương đối)
temp_min_c	°C	Nhiệt độ tối thiểu trong tuần
temp_max_c	°C	Nhiệt độ tối đa trong tuần
temp_range_c	°C	Biên độ nhiệt = temp_max_c – temp_min_c

Gió và độ ẩm (2 cột):

Tên cột	Đơn vị	Mô tả
humidity_pct	%	Độ ẩm tương đối (tính từ temp_c và dewpoint_c theo công thức August–Roche–Magnus)
wind_ms	m/s	Tốc độ gió tại độ cao 10m, tính từ thành phần u10 và v10

Lượng mưa và bốc hơi (4 cột):

Tên cột	Đơn vị	Mô tả
precip_mm	mm	Tổng lượng mưa
conv_precip_mm	mm	Lượng mưa đối lưu (giông, dông)
ls_precip_mm	mm	Lượng mưa quy mô lớn (front, low-pressure system)
evap_mm	mm	Lượng nước bốc hơi

Bức xạ mặt trời (3 cột):

Tên cột	Đơn vị	Mô tả
solar_wm2	W/m ²	Bức xạ mặt trời tổng cộng tại mặt đất

Tên cột	Đơn vị	Mô tả
uv_wm2	W/m ²	Bức xạ tia cực tím
thermal_wm2	W/m ²	Bức xạ nhiệt từ khí quyển xuống mặt đất

Khí quyển khác (4 cột):

Tên cột	Đơn vị	Mô tả
water_vapour	kg/m ²	Tổng hơi nước trong cột khí quyển
cloud_cover	0-1	Tỉ lệ mây bao phủ (0 = quang đãng, 1 = mây phủ kín)
msl_pa	Pa	Áp suất khí quyển quy về mực nước biển
blh_m	m	Độ cao lớp ranh giới khí quyển (boundary layer)

3. features_flu_v1.csv — Bộ feature cho mô hình cúm

Được tạo từ master_weekly_v1.csv bằng quá trình feature engineering. Mỗi dòng tương ứng với một mẫu huấn luyện hoặc dự báo.

Phạm vi: 146 quốc gia, giai đoạn 2010-2019. Số dòng giảm so với master file do loại bỏ những tuần đầu không đủ lịch sử để tính lag.

3.1. Cột định danh và target (5 cột)

Tên cột	Kiểu	Mô tả
iso3	string	Mã quốc gia ISO Alpha-3
iso_week	integer	Tuần ISO (1-52)
influenza_total	float	Target gốc (số ca cúm)
flu_log	float	Target đã transform log1p, dùng cho regression. Giúp giảm độ lệch phân phối

Tên cột	Kiểu	Mô tả
flu_risk_class	categorical	Nhân phân loại Low/Medium/High theo endemic channel Bortman 1999. Là target cho mô hình phân loại

3.2. Cột AR lag (3 cột) — đặc trưng tự hồi quy theo thời gian

Tên cột	Mô tả
flu_log_lag1	log1p(số ca cúm) của 1 tuần trước
flu_log_lag2	log1p(số ca cúm) của 2 tuần trước
flu_log_lag3	log1p(số ca cúm) của 3 tuần trước

3.3. Cột Rolling mean (2 cột) — đặc trưng trung bình trượt

Tên cột	Mô tả
flu_log_rollmean4	Trung bình log1p(số ca) qua 4 tuần gần nhất (tính từ t-1 trở về trước)
flu_log_rollmean8	Trung bình log1p(số ca) qua 8 tuần gần nhất

3.4. Cột Weather lag (6 cột) — đặc trưng thời tiết có độ trễ

Dựa trên kết quả phân tích Cross-Correlation Function (CCF) ở SESSION 4 EDA:

Tên cột	Mô tả	Tham chiếu
temp_c_lag3	Nhiệt độ trung bình 3 tuần trước	CCF lag 3, r=-0,37
temp_c_lag7	Nhiệt độ trung bình 7 tuần trước	Bổ sung
humidity_pct_lag1	Độ ẩm 1 tuần trước	CCF lag 1
humidity_pct_lag7	Độ ẩm 7 tuần trước	CCF lag 7, r=+0,31
solar_wm2_lag7	Bức xạ mặt trời 7 tuần trước	CCF lag 7, r=-0,41 (predictor mạnh nhất)
dewpoint_c_lag1	Điểm sương 1 tuần trước	CCF lag 1

Biến precip_mm đã loại khỏi flu features do CCF chỉ cho r=0,057 (không có tín hiệu).

3.5. Cột mã hóa thời gian và bán cầu (5 cột)

Tên cột	Mô tả
iso_week_sin	$\sin(2 \times \text{iso_week} / 52)$ — cyclic encoding
iso_week_cos	$\cos(2 \times \text{iso_week} / 52)$ — cyclic encoding
iso_year	Năm dạng số nguyên, capture xu hướng dài hạn
HEMISPHERE_NH	One-hot: 1 nếu thuộc Bắc bán cầu, 0 nếu không
HEMISPHERE_SH	One-hot: 1 nếu thuộc Nam bán cầu, 0 nếu không

4. features_dengue_v1.csv — Bộ feature cho mô hình sốt xuất huyết

Cấu trúc tương tự features_flu_v1.csv nhưng dùng lag dài hơn (chu kỳ sinh học của muỗi truyền bệnh ~ 2-3 tháng).

Phạm vi: 37 quốc gia, giai đoạn 2015-2019. Đã loại bỏ 9 quốc gia có coverage < 30 tuần/năm: ATG, CYM, GTM, HTI, SDN, SUR, TWN, VCT, WSM.

4.1. Cột định danh và target (5 cột)

Tên cột	Mô tả
iso3	Mã quốc gia ISO Alpha-3
iso_week	Tuần ISO
dengue_total	Target gốc (số ca sốt xuất huyết)
deng_log	Target đã transform log1p, dùng cho regression
dengue_risk_class	Nhân phân loại Low/Medium/High

4.2. Cột AR lag (5 cột)

Tên cột	Mô tả
deng_log_lag6	log1p(số ca dengue) của 6 tuần trước
deng_log_lag8	8 tuần trước
deng_log_lag10	10 tuần trước
deng_log_lag12	12 tuần trước
deng_log_lag14	14 tuần trước

4.3. Cột Rolling mean (2 cột)

Tên cột	Mô tả
deng_log_rollmean4	Trung bình trượt 4 tuần
deng_log_rollmean8	Trung bình trượt 8 tuần

4.4. Cột Weather lag (5 cột)

Theo CCF SESSION 4:

Tên cột	Mô tả	Tham chiếu
temp_c_lag11	Nhiệt độ 11 tuần trước	CCF $r=+0,31$, khớp Lowe 2014
dewpoint_c_lag8	Điểm sương 8 tuần trước	CCF $r=+0,31$
precip_mm_lag6	Lượng mưa 6 tuần trước	Chu kỳ sinh sản muỗi
humidity_pct_lag1	Độ ẩm 1 tuần trước	Effect tức thời
solar_wm2_lag16	Bức xạ mặt trời 16 tuần trước	Proxy mùa

4.5. Cột mã hóa thời gian (3 cột)

Tên cột	Mô tả
iso_week_sin	sin cyclic encoding
iso_week_cos	cos cyclic encoding
iso_year	Năm dạng số nguyên

5. Endemic channel — Định nghĩa nhân phân loại nguy cơ

Áp dụng phương pháp Bortman 1999 (chuẩn WHO EWARS):

Với mỗi tổ hợp (**iso3**, **iso_week**), tính từ training years: - **baseline_mean** = trung bình số ca lịch sử - **baseline_std** = độ lệch chuẩn

Nhân được gán theo công thức: - **Low**: số ca < baseline_mean - **Medium**: baseline_mean ≤ số ca < baseline_mean + 2 × baseline_std - **High**: số ca ≥ baseline_mean + 2 × baseline_std (ngưỡng cảnh báo bùng phát)

Training years: - Flu: 2010-2018 (val 2019) - Dengue: 2015-2018 (val 2019)

6. Tham khảo

- [1] R. Lowe et al., “Dengue outlook for the World Cup in Brazil: an early warning model framework driven by real-time seasonal climate forecasts”, *Lancet Infect. Dis.*, vol. 14, no. 7, pp. 619-626, Jul. 2014.
- [2] J. Shaman and M. Kohn, “Absolute humidity modulates influenza survival, transmission, and seasonality”, *PNAS*, vol. 106, no. 9, pp. 3243-3248, 2009.
- [3] M. Bortman, “Elaboración de corredores o canales endémicos”, *Boletín Epidemiológico de la OPS*, 1999.
- [4] World Health Organization, “FluNet — Global Influenza Surveillance and Response System”.
- [5] OpenDengue Project, “OpenDengue v1.3 — Global dengue surveillance data”.
- [6] H. Hersbach et al., “The ERA5 global reanalysis”, *Quarterly Journal of the Royal Meteorological Society*, vol. 146, no. 730, pp. 1999-2049, Jul. 2020.